

Prepoznavanje bolesti biljaka pomoću konvolucionih neuronskih mreža

Analiza generalizacije modela sa laboratorijskih na stvarne terenske snimke

Model obučen na standardnom skupu PlantVillage postiže tačnost od 99,65 %. Isti model, na fotografijama istih bolesti snimljenim u stvarnom polju, tačan je u 14,83 % slučajeva. Ovaj rad ispituje odakle potiče ta razlika i šta ona znači za primenljivost ovakvih modela.

Laboratorija	Teren	Prepoznavanje biljke	Kontrolni skup
99,65 %	14,83 %	99,86 → 28,80 %	97,71 %
test skup PlantVillage	terenski snimci PlantDoc	pad na istom zadatku	provera ispravnosti koda

1. Uvod i motivacija

Automatsko prepoznavanje bolesti biljaka sa fotografije lista jedan je od najčešćih zadataka u primenjenom mašinskom učenju u poljoprivredi. Praktični cilj je jasan: poljoprivrednik fotografiše list telefonom i dobija dijagnozu.

Gotovo svi radovi iz ove oblasti koriste isti skup podataka — PlantVillage — prijavljuju tačnost preko 99 % i tu se zaustavljaju. Problem je u tome što svaka slika u tom skupu predstavlja studijski snimak: jedan otkinut list, centriran u kadru, na jednoličnoj sivoj pozadini i pri ujednačenom osvetljenju.

Pošto i skup za obuku i skup za testiranje potiču iz iste raspodele, visoka tačnost na test skupu potvrđuje samo jedno: da je model naučio tu raspodelu. Ona ne govori ništa o tome da li je model naučio patologiju biljaka ili je jednostavno naučio da prepozna jednu fotografsku konvenciju.

Da bi se to razdvojilo, potrebno je promeniti fotografije, a zadržati isto pitanje. Zato je model ovde obučen na skupu PlantVillage, a zatim testiran — bez ikakvog dodatnog prilagođavanja ili dodatne obuke — na skupu PlantDoc, koji sadrži iste bolesti na istim kulturama, ali fotografisane u stvarnim poljskim uslovima.

2. Podaci

Korišćena su tri skupa podataka. Svi su preuzeti u parquet formatu, bez izvršnih skripti za učitavanje; parametar `trust_remote_code` nikada nije postavljen, čime je isključeno izvršavanje tuđeg koda na lokalnoj mašini.

Skup podataka	Uloga	Obim	Uslovi snimanja
PlantVillage	obuka, validacija, test	55.448 slika / 39 klasa	studijski, jednolična pozadina
PlantDoc	nezavisan test	2.569 slika / 28 klasa	stvarno polje, složena pozadina
PlantVillage (kopija)	kontrola ispravnosti	8.000 slika / 38 klasa	studijski, drugi izvor

2.1. Priprema podataka

Skup PlantVillage podeljen je stratifikovano u odnosu 70/15/15 na skupove za obuku (38.812 slika), validaciju (8.317) i testiranje (8.319). Stratifikacija je bila neophodna jer je skup izrazito neuravnotežen — najbrojnija klasa ima oko 5.000 slika, a najređa svega 150. Nasumična podela ostavila bi retke klase sa premalo test primera da bi njihova F1 mera bila stabilna.

Svih 28 klasa skupa PlantDoc preslikano je na odgovarajuće klase skupa PlantVillage. To preslikavanje je ključni deo eksperimenta: bez njega se modelu ne postavlja isto pitanje za koje je obučen. Preslikavanje se vrši u trenutku pripreme podataka, tako da evaluacija na terenskom skupu koristi potpuno isti kod kao i evaluacija na laboratorijskom.

2.2. Kontrolni skup

Tvrđenje „model ne generalizuje“ i „preslikavanje klasa je pogrešno“ daju identičan rezultat — nulu ili blizu nule. Da bi se te dve mogućnosti razdvojile, model je testiran i na nezavisno pripremljenoj kopiji skupa PlantVillage, koju je objavio drugi autor i koja koristi drugačija imena klasa. Ako kod za preslikavanje i evaluaciju radi ispravno, na toj kopiji rezultat mora biti visok.

3. Metodologija

3.1. Arhitektura modela

Kao osnovni model korišćena je konvoluciona neuronska mreža ResNet18, prethodno obučena na skupu ImageNet, sa 11.196.519 parametara. Poslednji sloj zamenjen je novim, prilagođenim broju klasa (39). Radi poređenja, pod istim uslovima obučena je i mreža ResNet9 sa nasumičnom inicijalizacijom — arhitektura iz polaznog rada, sa 6.588.007 parametara.

3.2. Augmentacija podataka

Nad slikama za obuku primenjena je namerno agresivna augmentacija: nasumično isecanje i skaliranje, horizontalno i vertikalno preslikavanje, rotacija do 20 stepeni, promena osvetljenosti, kontrasta, zasićenja i nijanse, kao i nasumično brisanje delova slike.

Razlog je upravo jednoličnost polaznog skupa. Bez augmentacije mreža lako nauči sporedne pravilnosti — nijansu pozadine, položaj lista u kadru — umesto same bolesti. Preslikavanje i rotacija su ovde dozvoljeni jer list nema prirodnu orijentaciju.

3.3. Postupak obuke


Obuka je trajala 12 epoha, uz optimizator AdamW, OneCycle raspored stope učenja, odsecanje gradijenta i ublažavanje oznaka. Korišćena je mešovita preciznost (AMP) radi ubrzanja.

Model je biran prema makro F1 meri na validacionom skupu, a ne prema tačnosti. Kod ovako neuravnoteženog skupa tačnost bi favorizovala česte klase i birala modele koji su dobri na njima, a ravnodušni prema retkim bolestima.

3.4. Mere kvaliteta i njihovo značenje

Umesto jedne brojke, praćeno je nekoliko mera, jer svaka otkriva drugačiju vrstu greške:

- Tačnost — udeo ispravno klasifikovanih slika. Kod neuravnoteženih skupova može biti visoka i kada model retke klase uopšte ne prepoznaje.
- Balansirana tačnost i makro F1 — daju svakoj klasi jednaku težinu, pa otkrivaju upravo taj problem.
- Preciznost i odziv — preciznost pokazuje koliko su prijavljene dijagnoze pouzdane, a odziv koliko bolesnih biljaka model uopšte pronađe.
- Koenova kapa — poredi model sa slučajnim pogađanjem uz istu raspodelu klasa.
- Kalibracija (ECE) — meri da li prijavljena pouzdanost odgovara stvarnoj tačnosti; odgovara na pitanje da li model zna kada greši.
- Grad-CAM — vizuelna analiza koja pokazuje na koje delove slike se model zapravo oslanja.




Slika 1. Tok obuke. Levo: funkcija gubitka; desno: tačnost i makro F1 na validacionom skupu. Tačnost prelazi 99 % do sedme epohe. Ništa na ovom grafiku ne nagoveštava problem opisan u nastavku — što je i suština: krive obuke unutar istog domena ne mogu otkriti grešku van njega.

5. Rezultati na terenskim snimcima

Isti model, iste težine, istih 28 klasa — ali fotografije snimljene napolju. Tačnost pada sa 99,60 % na 14,83 %, što je relativan pad od 85,1 %. Za poređenje, nasumično pogađanje na 28 klasa daje 3,6 %.

Mera	Laboratorija	Teren	Zadržano
Tačnost	0,9960	0,1483	14,9 %
Balansirana tačnost	0,9948	0,1425	14,3 %
Makro F1	0,9944	0,1602	16,1 %
Makro preciznost	0,9942	0,3551	35,7 %
Top-5 tačnost	1,0000	0,4352	43,5 %
Koenova kapa	0,9958	0,1308	13,1 %
Prepoznavanje biljke	0,9986	0,2880	28,8 %
Zdravo / bolesno	0,9991	0,7415	74,2 %



Slika 3. Poređenje istog modela na laboratorijskim i terenskim snimcima, na istih 28 klasa. Sve mere padaju, ali ne podjednako.

5.1. Model ne prepoznaje ni samu biljku

Najblaže pitanje koje se modelu može postaviti jeste koja se biljka nalazi na slici, bez obzira na bolest. To je zadatak sa 14 mogućih odgovora i očiglednim vizuelnim tragovima — oblik lista, veličina, nervatura. U laboratorijskim uslovima model na njega odgovara tačno u 99,86 % slučajeva. Na terenu — u 28,80 %.

Dakle, ne radi se o suptilnoj zameni sličnih bolesti. Model često ne prepoznaje ni vrstu biljke koju gleda.


Najrečitiji podatak

34,9 % terenskih fotografija model svrstava u klasu „Background_without_leaves“, koja u skupu PlantVillage označava da na slici uopšte nema lista. Suočen sa fotografijom bolesne biljke koja raste u polju, najčešći odgovor modela jeste da na slici nema lista. Model je naučio da „list“ znači primerak izolovan na sivoj studijskoj pozadini — list na živoj biljci za njega više ne predstavlja list.

5.2. Jedina naizgled prihvatljiva mera nije stvarna

Svođenje zadatka na binarno pitanje — da li je biljka bolesna ili zdrava — daje 74,15 % na terenu, što deluje upotrebljivo. Nije. U skupu PlantDoc 67,07 % slika zaista jeste bolesna, pa odgovor „bolesna“ na svaku sliku bez razmišljanja daje 67,07 %. Model predviđa „bolesna“ u 85,29 % slučajeva, uz odziv od 94,31 % i preciznost od 74,17 %.

Sedam procentnih poena iznad konstantnog odgovora nije alat za trijažu. To je model sa jakom sklonošću ka odgovoru „bolesna“, primenjen na skup u kome je većina biljaka bolesna.




Slika 4. F1 mera po klasama u oba domena, sortirano po uspehu na terenu. Pad je širok, a ne skoncentrisan na nekoliko klasa.

6. Referentni skup pogrešno rangira modele

Sve prethodno odnosi se na jedan model. Prirodno pitanje je da li druga arhitektura izbegava problem. Zato je mreža ResNet9 sa nasumičnom inicijalizacijom obučena pod potpuno istim uslovima: ista podela podataka, ista augmentacija, isti raspored stope učenja, istih 12 epoha, isti kriterijum izbora modela. Razlikuju se samo arhitektura i odsustvo pretreniranja na skupu ImageNet.

Model	Referentni skup	Teren	Relativni pad
ResNet9 (bez pretreniranja)	99,72 %	9,85 %	90,1 %
ResNet18 (ImageNet)	99,65 %	14,83 %	85,1 %



Slika 5. Tačnost dva modela na referentnom skupu i na terenu. Na referentnom skupu su praktično jednaki; na terenu se razlikuju za oko 50 %.

Na referentnom skupu model bez pretreniranja je čak i bolji — 99,72 % naspram 99,65 % — i to sa manje parametara. Na terenu postiže 9,85 % naspram 14,83 %, dakle za trećinu lošiji rezultat.


Ovo je praktično najvažniji nalaz rada. Nije problem samo u tome što je brojka sa referentnog skupa naduvana — referentni skup aktivno obrće redosled. Izbor modela prema tačnosti na izdvojenom test skupu, a upravo tako se model bira u praksi, vodi ka mreži koja je u stvarnim uslovima znatno lošija.

7. Model nije svestan sopstvenih grešaka

Model koji greši može se kontrolisati ako svoju nesigurnost prijavljuje. Opasna je samouverena greška.

Na laboratorijskim slikama model je dobro kalibrisan: greška kalibracije iznosi 0,0414, a od 97,1 % predviđanja datih sa pouzdanošću preko 90 %, tačno je 99,9 %. Prijavljena pouzdanost znači ono što tvrdi.

Na terenskim slikama greška kalibracije raste više od deset puta, na 0,4370. Model i dalje daje ocenu pouzdanosti veću od 90 % za 12,7 % fotografija — a od tih predviđanja tačno je svega 22,2 %. Na slikama koje pogreši ostaje u proseku 57,6 % siguran.



Slika 6. Dijagrami pouzdanosti. Tačke na isprekidanoj dijagonali označavaju savršenu kalibraciju. Levi panel je prati; desni je duboko ispod nje — pri najvišoj prijavljenoj pouzdanosti model je tačan u oko četvrtini slučajeva.


Šta to znači u praksi

Aplikacija zasnovana na ovom modelu prikazala bi korisniku pogrešnu dijagnozu bez ikakvog znaka nesigurnosti. Za poljoprivrednika to znači pogrešno primenjeno sredstvo ili propuštenu bolest, uz puno poverenje u prikazani rezultat.

8. Na šta se model zapravo oslanja


Tačnost sama po sebi ne može razlikovati model koji čita lezije na listu od modela koji čita pozadinu — oba postižu visok rezultat u laboratoriji. Grad-CAM odgovara na to pitanje neposredno, prikazujući od kojih piksela zavisi ocena predviđene klase.

Grad-CAM — PlantVillage, test skup (laboratorijski uslovi)



Slika 7. Laboratorijski snimci: pažnja pokriva ceo obris lista, a ne konkretne lezije — što odgovara modelu koji se oslanja na opšti oblik i boju naspram predviđive pozadine. Drugi panel prikazuje klasu „Background_without_leaves“, koja sadrži stok fotografije, u ovom slučaju ovaca.

Grad-CAM — PlantDoc (stvarni terenski snimci)



Slika 8. Terenski snimci: pažnja se rasipa na sve što je u kadru. Šest od osam predviđanja je pogrešno. Krompir koji raste u zemlji označen je kao „Background without leaves“, sa pažnjom na tlu između stabljika. Tamo gde model uspeva, kao kod pegavosti kukuruza, pažnja jeste na samoj leziji.

Kvantitativno, udeo Grad-CAM pažnje koji pada na rubni deo kadra iznosi 0,649 za laboratorijske i 0,667 za terenske snimke, pri čemu bi 0,750 značilo potpuno ravnomernu raspodelu. Na terenu je pažnja merljivo rasutija — model nema centrirani primerak na koji bi se oslonio, pa se dokazi razlivaju po celoj slici.

9. Zaključak

Visoka tačnost na skupu PlantVillage ne meri prepoznavanje bolesti. Ona meri koliko je dobro model naučio jednu fotografsku konvenciju.

To ima značaja i izvan ovog jednog skupa, jer se upravo ta brojka najčešće citira. Tvrdnja o 99 % tačnosti podrazumeva alat koji poljoprivrednik može uperiti u biljku. Rezultati pokazuju da bi takav alat grešio u šest od sedam slučajeva, često tvrdio da na slici uopšte nema lista, i pritom ne bi prijavljivao nikakvu nesigurnost.

9.1. Mere koje bi stvarno pomogle

- Uključiti terenske snimke u samu obuku. Problem je pre svega u podacima, a tek onda u modelu; i mala količina stvarnih snimaka menja ono na šta se model može osloniti.
- Uvek prijavljivati rezultate na nezavisnom skupu. Podela unutar istog skupa ne može otkriti ovaj problem, pa ni ispravno rangirati modele.
- Segmentacija lista pre klasifikacije, čime se uklanja pozadina kao prečica — uz cenu potrebe za dodatnim oznakama.
- Uvesti prag pouzdanosti i mogućnost odgovora „nisam siguran“, umesto samouverene pogrešne dijagnoze.

9.2. Ograničenja rada

Skup PlantDoc nije savršen instrument. Njegove oznake su šumovitije od PlantVillage, deo slika su stok fotografije umesto stvarnih terenskih snimaka, a preslikavanje klasa između dva skupa urađeno je ručno. Jedan deo izmerene razlike stoga potiče od kvaliteta podataka, a ne isključivo od promene domena.

Ipak, šum u oznakama ne može objasniti to što model trećinu slika proglašava slikama bez lista, niti pad prepoznavanja same biljke na 28,8 %. Za takav rezultat potrebno je da model čita nešto drugo, a ne biljku.

Kontrolni eksperiment dodatno potvrđuje ovaj zaključak: na nezavisno pripremljenoj kopiji skupa PlantVillage, kroz potpuno isti kod za evaluaciju, model postiže 97,71 % tačnosti. Pad na terenskim snimcima nije posledica greške u obradi podataka.